PROYECTO INTEGRADOR FINAL

AUA - Sistema Inteligente de Gestión de Pedidos de Agua Embotellada

Alumna:
Agustina Chavez

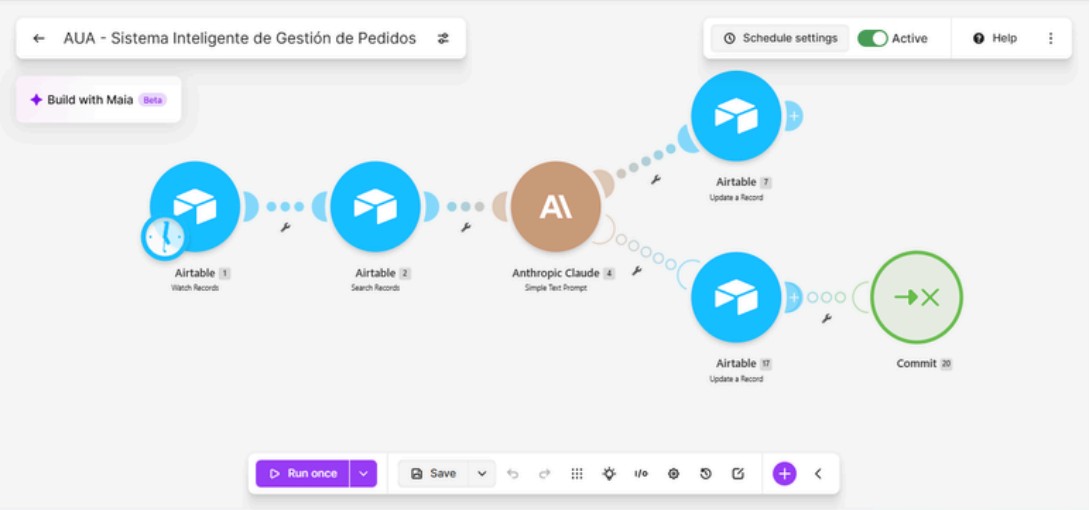
Tecnologías utilizadas:

- Make
- Airtable
- Anthropic Claude Haiku 4.5
- Gmail
- RAG (Base de Conocimiento interna)
- Human-in-the-Loop (HITL)

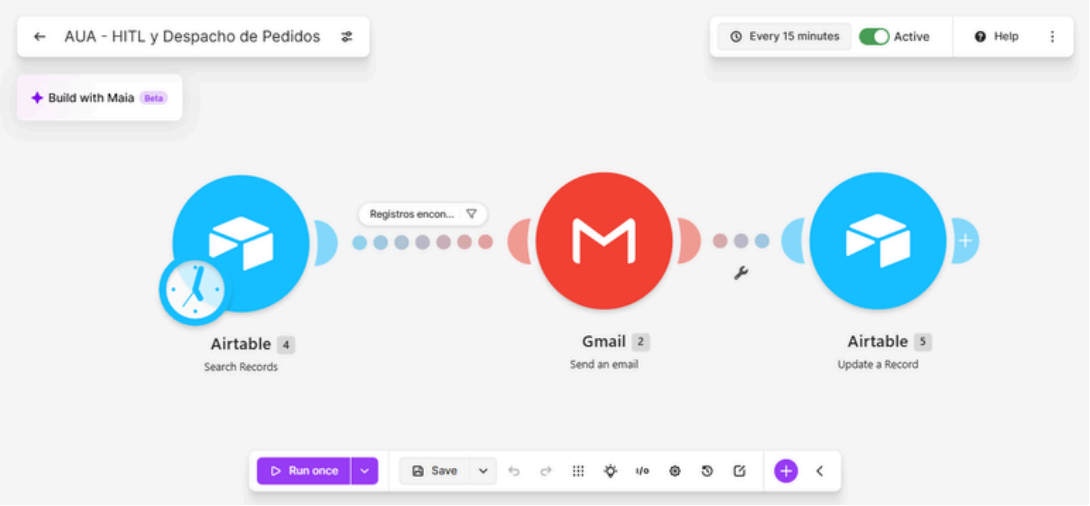
1. DIAGRAMA DE ARQUITECTURA

El sistema fue implementado mediante una arquitectura asíncrona de dos escenarios independientes.

Escenario 1: Procesamiento Inteligente de Pedidos



Escenario 2: Human-in-the-Loop y Despacho



Video Demo

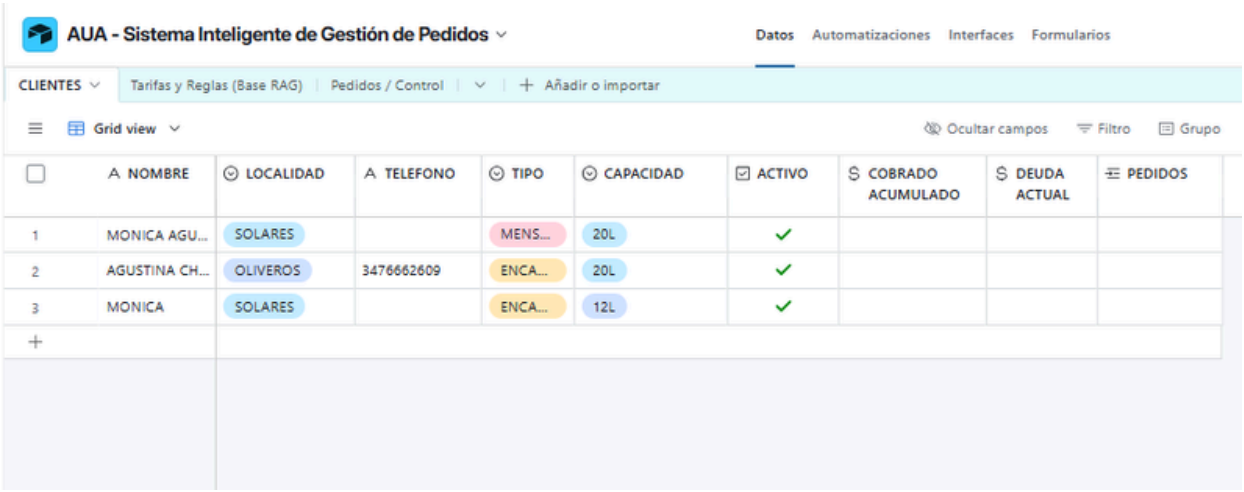
https://drive.google.com/file/d/19o7-VshS8vRvPl85FHFTVWUGKyVmLzaU/view?usp=sharing

2. MANUAL OPERATIVO DE DATOS

Base de Datos

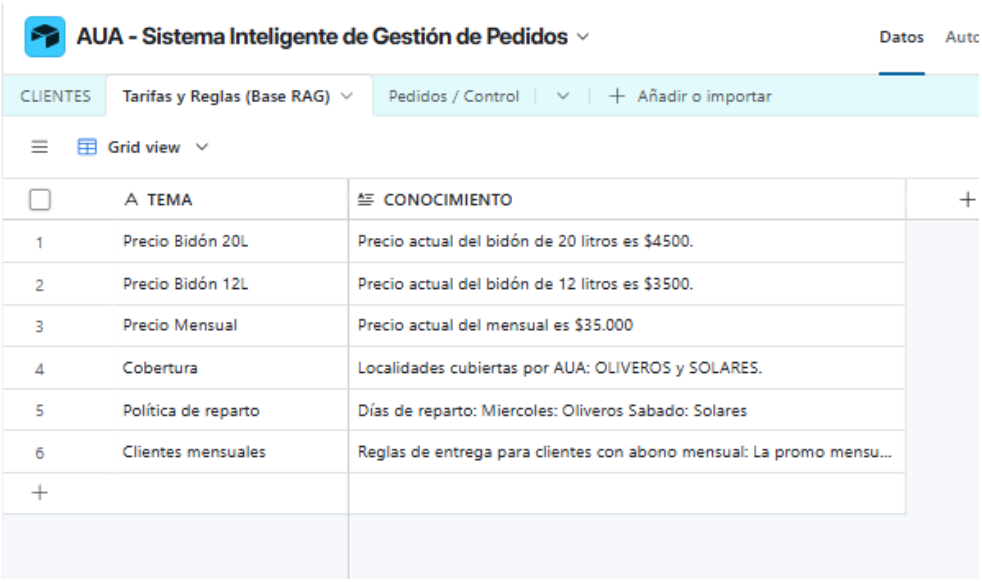
La solución utiliza Airtable como repositorio central.

Tabla CLIENTES



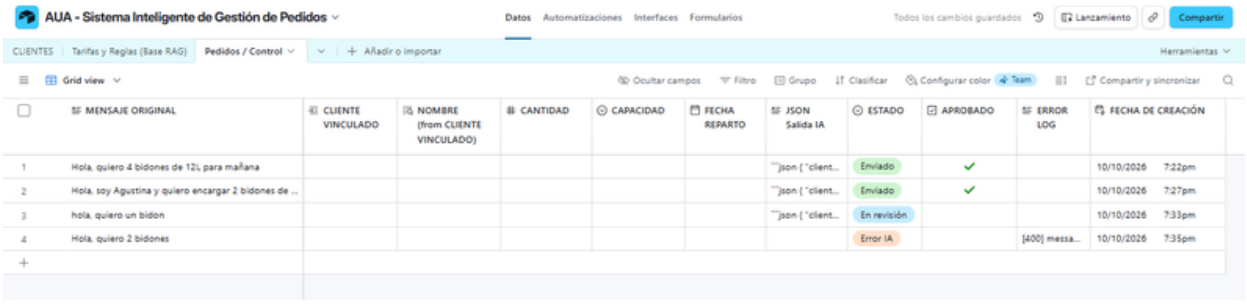
	NOMBRE	LOCALIDAD	TELEFONO	TIPO	CAPACIDAD	ACTIVO	COBRADO ACUMULADO	DEUDA ACTUAL	PEDIDOS
1	MONICA AGU...	SOLARES		MENS...	20L	✓			
2	AGUSTINA CH...	OLIVEROS	3476662609	ENCA...	20L	✓			
3	MONICA	SOLARES		ENCA...	12L	✓			

Tabla TARIFAS Y REGLAS (Base RAG)



	TEMA	CONOCIMIENTO
1	Precio Bidón 20L	Precio actual del bidón de 20 litros es $4500.
2	Precio Bidón 12L	Precio actual del bidón de 12 litros es $3500.
3	Precio Mensual	Precio actual del mensual es $35.000
4	Cobertura	Localidades cubiertas por AUA: OLIVEROS y SOLARES.
5	Política de reparto	Días de reparto: Miercoles: Oliveros Sabado: Solares
6	Clientes mensuales	Reglas de entrega para clientes con abono mensual: La promo mensu...

Tabla PEDIDOS / CONTROL



	MENSAJE ORIGINAL	CLIENTE VINCULADO	NOMBRE (from CLIENTE VINCULADO)	CANTIDAD	CAPACIDAD	FECHA REPARTO	JSON Salida IA	ESTADO	APROBADO	ERROR LOG	FECHA DE CREACIÓN
1	Hola, quiero 4 bidones de 12L para mañana						"json { "client...	Enviado	✓		10/10/2026 7:22pm
2	Hola, soy Agustina y quiero encargar 2 bidones de ...						"json { "client...	Enviado	✓		10/10/2026 7:27pm
3	hola, quiero un bidon						"json { "client...	En revisión			10/10/2026 7:33pm
4	Hola, quiero 2 bidones							Error IA		[400] messa...	10/10/2026 7:35pm

Esquema JSON de la IA:

```
{
"cliente": null,
"localidad": null,
"cantidad": 4,
"capacidad": 20,
"tipo": "bidón",
"prioridad": "sábado"
}
```

3. MATRIZ DE COSTOS

1. Estimación de consumo por ejecución (Pedido promedio)

Un pedido típico procesado en tu Escenario 1 consume aproximadamente:
Tokens de entrada (Prompt + RAG + Mensaje cliente): ~1.000 tokens.
Tokens de salida (JSON estructurado / respuesta): ~300 tokens.
Volumen base mensual para proyectar: 1.000 pedidos/mes.

2. Tarifas oficiales de referencia (por millón de tokens - MTok)

Modelo	Input (por 1M tokens)	Output (por 1M tokens)
Claude 3.5 Haiku (Mi elección)	$0.80 USD	$4.00 USD
GPT-4o mini (Alternativa ligera)	$0.15 USD	$0.60 USD
Claude 3.5 Sonnet (Modelo pesado / alta capacidad)	$3.00 USD	$15.00 USD

3. Cuadro comparativo

Modelo evaluado	Costo por ejecución (1.000 in / 300 out)	Costo mensual (1.000 ejecuciones)	Latencia típica	Nivel de precisión / Formato JSON	Viabilidad para el proyecto
Claude 3.5 Haiku *(Implementado)*	**$0.0020 USD**	**$2.00 USD**	Rápida (< 1.2s)	Excelente seguimiento de esquemas JSON estrictos	**Óptima:** Balance ideal entre bajo costo, velocidad y precisión en extracción.
GPT-4o mini	$0.0003 USD	$0.33 USD	Muy rápida (< 1s)	Buena, con leve riesgo de deriva en formatos complejos	**Alta:** Opción económica viable, aunque con menor consistencia en prompts largos.
Claude 3.5 Sonnet	$0.0075 USD	$7.50 USD	Moderada (~ 2.5s)	Máxima capacidad de razonamiento	**Inviable / Sobredimensionado:** Sobrecostea 3.75x el flujo para una tarea de extracción puntual.

Se seleccionó Claude 3.5 Haiku como el motor de IA para el procesamiento de pedidos debido a su balance óptimo entre latencia reducida y estricto seguimiento de instrucciones para salida estructurada (JSON). Comparado con modelos de gama alta como Claude 3.5 Sonnet, reduce los costos operativos en casi un 75% sin degradar la precisión en la extracción de ítems y entidades, mientras que frente a opciones más económicas ofrece mayor consistencia ante entradas ambiguas del cliente

4. SEGURIDAD Y RESILIENCIA

- **Minimización de datos**

El sistema procesa únicamente la información necesaria para generar pedidos:

- **Cantidad**
- **Capacidad**
- **Tipo**
- **Prioridad**
- **No almacena información sensible adicional.**

- **Human-in-the-Loop**

Se implementó un punto de validación humana obligatorio.

Flujo:

IA
↓
En revisión
↓
Operador valida
↓
Correo al cliente

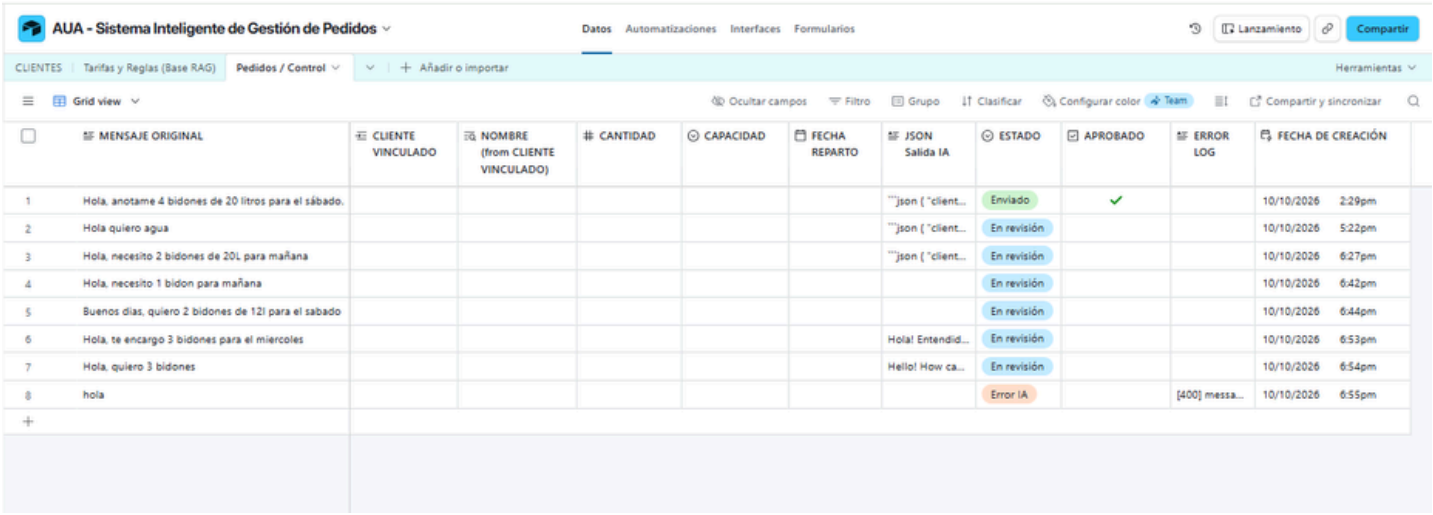
Esto evita acciones automáticas incorrectas.

- **Error Handling**

Se implementó una ruta alternativa para errores de IA.

Claude
↓ Error
Update Record
↓
Estado = Error IA
↓
Error Log
↓
Commit

Evidencia de Resiliencia



5. DASHBOARD DE CONTROL

Objetivo:

Monitorear en tiempo real la salud operativa, la demanda del negocio y la estabilidad del procesamiento automatizado con IA.

El dashboard fue implementado en Airtable Interfaces para monitorear en tiempo real la operación del procesados.

KPIs supervisados

- **Total de pedidos recibidos.**
- **Pedidos en revisión.**
- **Pedidos enviados.**
- **Pedidos con Error IA.**
- **Tasa de error IA.**
- **Tasa de aprobación humana.**

Visualizaciones

- **Distribución de estados del flujo.**
- **Distribución por capacidad de producto (12L y 20L).**
- **Evolución temporal de pedidos procesados.**

Shared View:

https://airtable.com/invite/l?inviteId=inviv2u9WCgYw2TGI&inviteToken=71845dd30889b93c6acb695102b6c5993797a558d719a2b88adadb53cd67382a&utm_medium=email&utm_source=product_team&utm_content=transactional-alerts

ANEXOS
Blueprint Escenario 1
Link:

https://drive.google.com/file/d/186CHSZNZ-gVOgjxHN0B916XbDWFOkGHh/view?usp=sharing

Blueprint Escenario 2
Link:

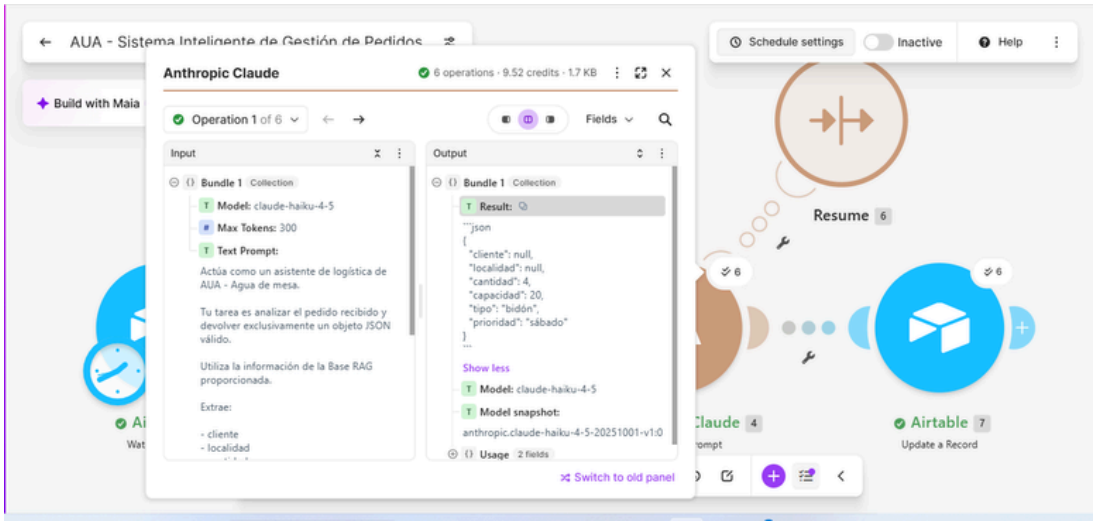
https://drive.google.com/file/d/16rbW0OiKOCBh90gChaQBjgxJkTYdBlwh/view?usp=sharing

Base de datos:

https://airtable.com/invite/l?inviteId=inviv2u9WCgYw2TGI&inviteToken=71845dd30889b93c6acb695102b6c5993797a558d719a2b88adadb53cd67382a&utm_medium=email&utm_source=product_team&utm_content=transactional-alerts

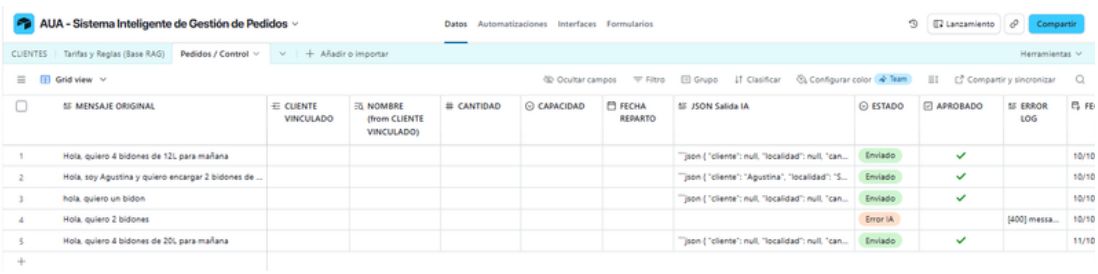
Evidencias

Caso feliz 1:

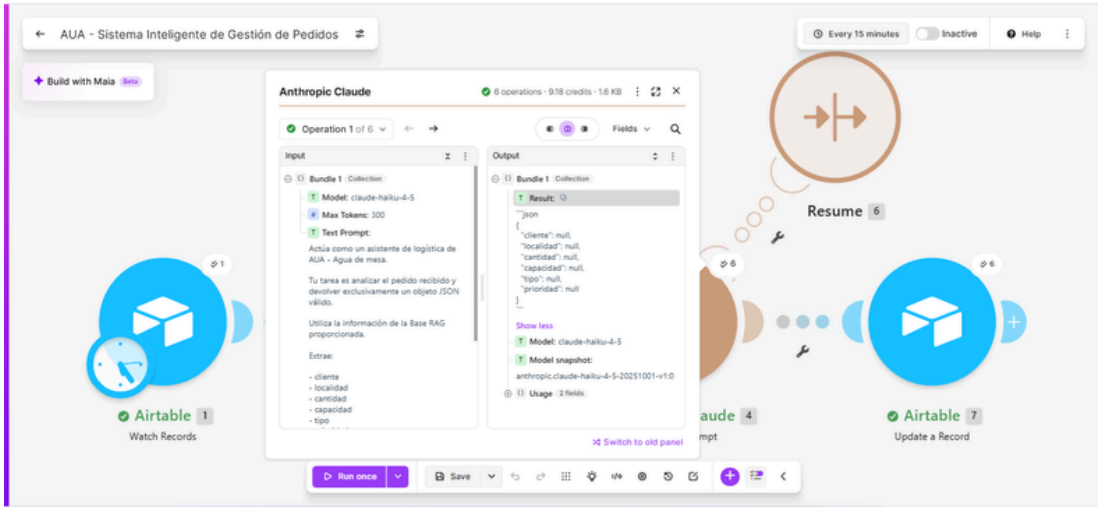


Ambos casos se encuentran completados y en estado enviado.

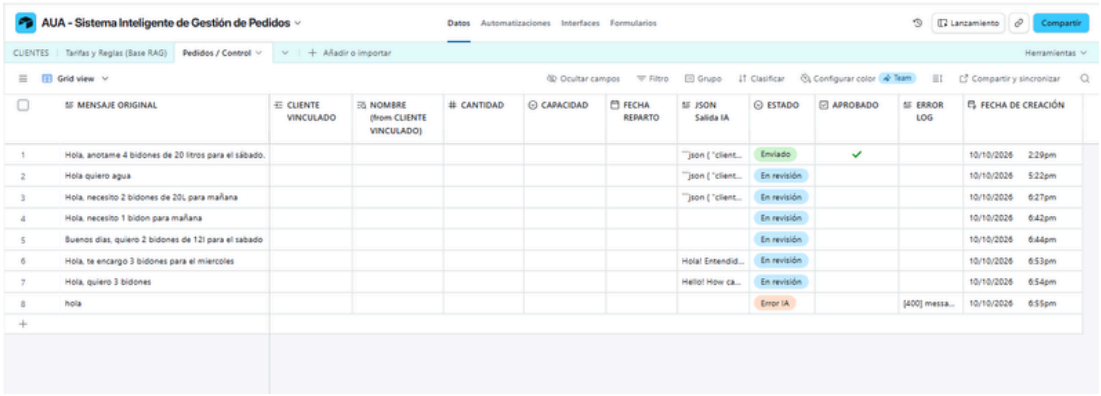
Caso feliz 2:



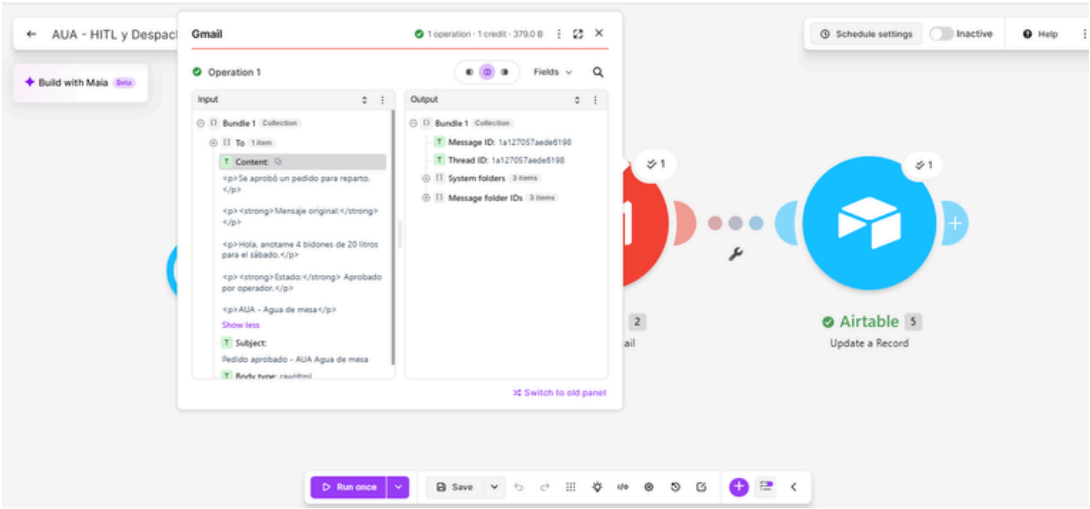
Caso infeliz:



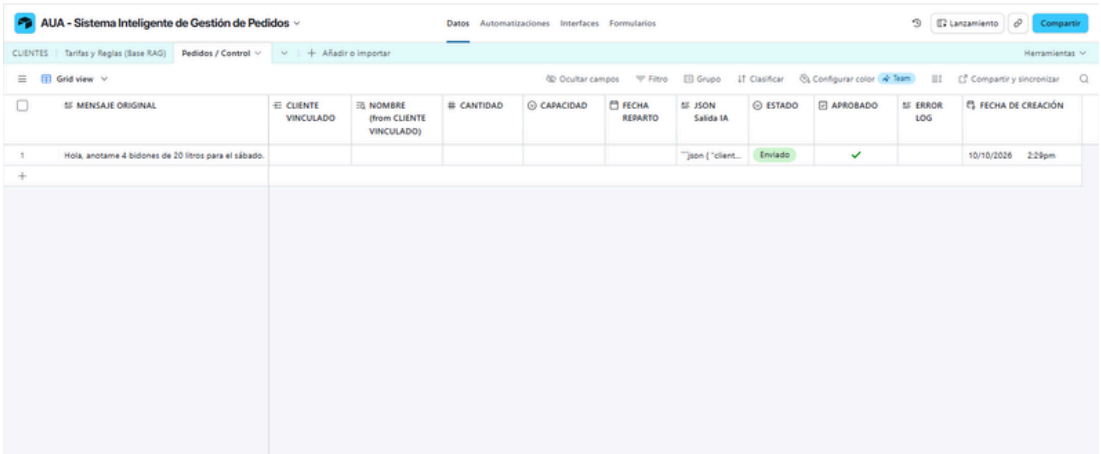
Error IA:



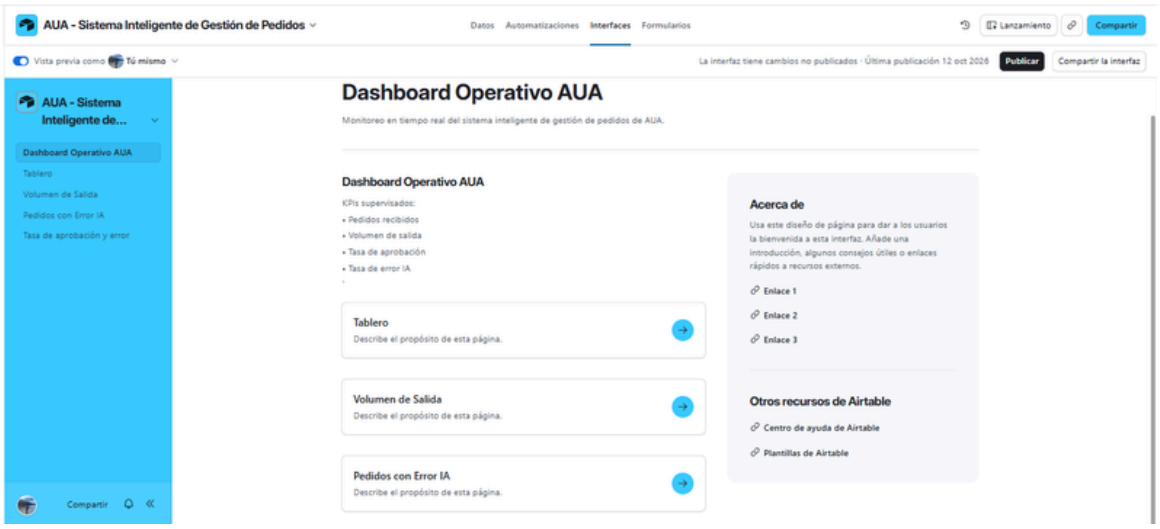
Correo Gmail:



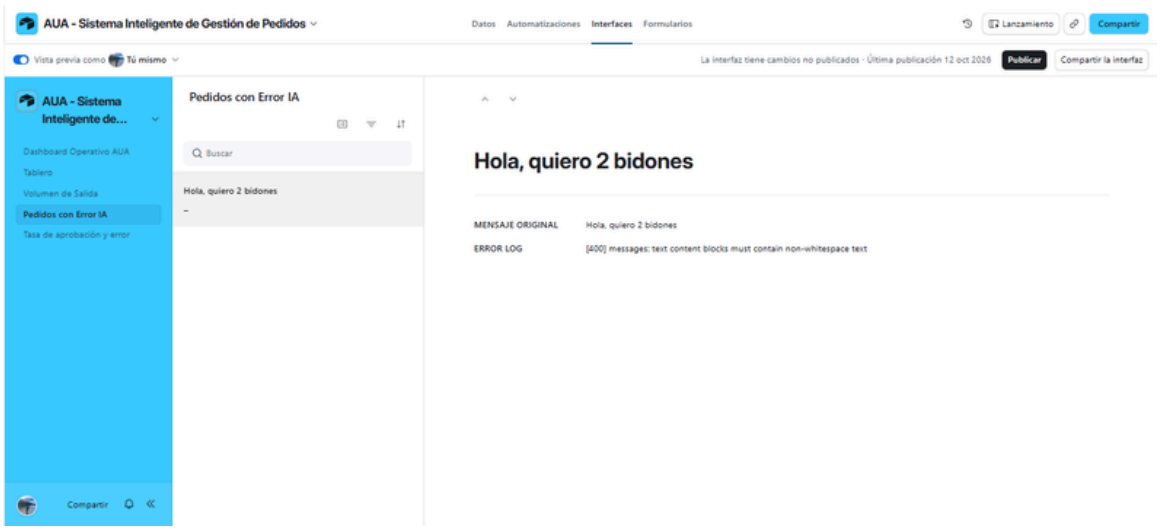
Estado Enviado:

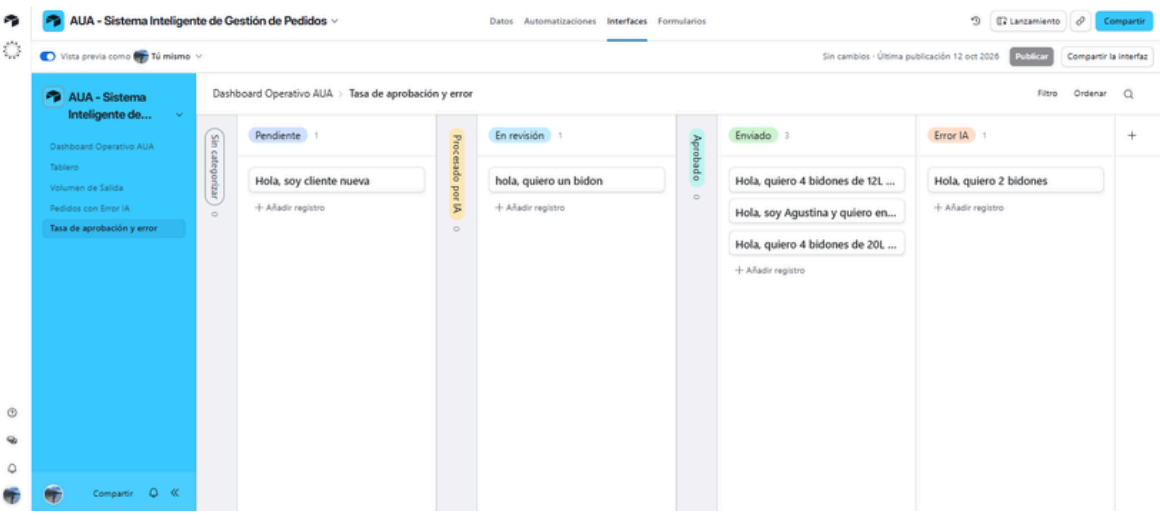


5. DASHBOARD DE CONTROL









6. CONCLUSIONES Y PRÓXIMOS PASOS

Conclusiones técnicas:

Arquitectura desacoplada y asíncrona: La separación en dos escenarios independientes resolvió el riesgo del "efecto metralleta", garantizando que ninguna comunicación externa se dispare sin la validación explícita del operador humano (HITL).

Eficiencia y costo-beneficio:

La selección de Claude 3.5 Haiku demostró ser la alternativa óptima para la extracción de datos y estructuración JSON, combinando baja latencia, alta fidelidad al esquema y un costo por ejecución inferior a $0.0020 USD.

Resiliencia operativa:

La implementación de directivas de manejo de errores (Error Handlers) asegura que los fallos de red o de API no generen interrupciones silenciosas, canalizando las anomalías hacia estados auditables en Airtable para su rápida resolución.

Próximos pasos y escalabilidad:

Validación automática de inventario:

Integrar una consulta directa de stock antes de pasar el pedido al estado "En revisión".
Alertas proactivas al equipo técnico: Disparar una notificación instantánea (por Slack o canal interno) en caso de que un registro pase al estado Error IA.

Optimización de prompts:

Continuar iterando el contexto dinámico (RAG) para reconocer promociones estacionales y solicitudes complejas con múltiples productos.

7. REPOSITORIO Y ACCESO

Repositorio de GitHub:

https://github.com/agusschavez-17/proyecto-final-aua-gestion-pedidos